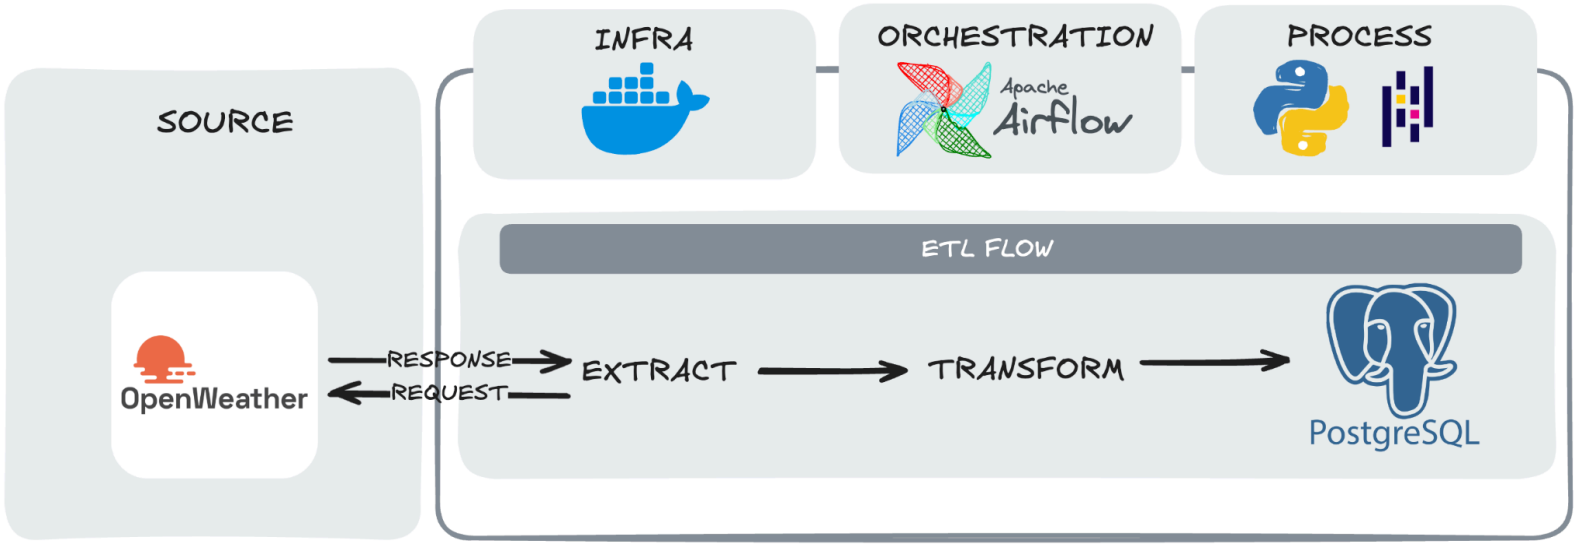
Engenharia de Dados na Prática: Pipeline ETL de dados meteorológicos - Nível Iniciante



Requisitos e Configurações do Projeto

1. Pré-requisitos de Software (Ambiente Local)

- **Editor de Código:** VS Code (recomendado com extensões Python e Docker).
- **Linguagem:** Python 3.12 ou superior.
- **Banco de Dados:** PostgreSQL 14+ rodando localmente (via Homebrew no Mac).
- **Containerização:** Docker Desktop para execução do ecossistema Airflow.
- **UV (Gerenciador de pacotes python)**

☐ **API Externa:** Conta ativa no OpenWeatherMap com uma **API Key** gerada.

---

2. Configuração do Banco de Dados (PostgreSQL)

☑ ~~**Role (Usuário):** Criação de uma identidade dedicada para o pipeline.~~
☑ ~~**Privilégios:** Concessão de todas as permissões para o usuário criado~~
☑ ~~**Database:** Criação do banco de dados `weather_data` como destino final do ETL.~~

---

3. Orquestração (Apache Airflow)

A automação será gerenciada via Docker Compose:

- **Infraestrutura:** Utilização da imagem oficial `apache/airflow:3.1.7`. curl -LfO 'https://airflow.apache.org/docs/apache-airflow/3.1.7/docker-compose.yaml'
- **DAG Definition:** Desenvolvimento do pipeline utilizando a **TaskFlow API** (`@task`).
- **Volumes:** Mapeamento de pastas locais (`/dags`, `/src`, `/data`) para dentro do container.

---

4. Desenvolvimento Python (Scripts ETL)

O core do projeto será dividido em módulos para garantir a manutenção:

☐ **Extração:** Script para requisição dos dados JSON da API OpenWeather.
☐ **Transformação:** Utilização da biblioteca **Pandas** para limpeza, normalização e conversão de tipos
☐ **Carga:** Implementação de conexão via **SQLAlchemy** e **psycopg2** para ingestão dos dados no PostgreSQL
